

LAPORAN UAS DEEP LEARNING

TEXT SUMMARIZATION PADA UNIVERSITAS BENGKULU MENGUNAKAN ARSITEKTUR ENCODE – DECODER DAN ATTENTION LSTM



DISUSUN OLEH:

Rosalia Dina Marina Sipahutar	G1A021017
Esti Asmareta Ayu	G1A021042
Mira Juwita Ali	G1A021056

DOSEN PENGAMPU

Arie Vatesia, S.T., M.T.I., Ph.D.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2024

DAFTAR ISI

DAFTAR ISI.....	i
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah.....	2
1.4 Tujuan Penelitian	2
1.5 Manfaat Penelitian	2
BAB II TINJUAN PUSTAKA	3
2.1 <i>Deep Learning</i>	3
2.2 <i>Text Summarization</i>	3
2.3 <i>Attention Mechanism</i>	3
2.4 <i>Long Short – Term Memory (LSTM)</i>	4
2.5 <i>Encoder – decoder</i>	4
BAB III HASIL DAN PEMBAHASAN	5
3.1 <i>Business Understanding</i>	5
3.2 <i>Data Understaning</i>	5
3.3 <i>Data Preparation</i>	5
3.4 <i>Modeling</i>	6
3.5 Evaluasi	6
3.6 Analisa Model sebagai <i>Deep Learning</i>	8
BAB IV KESIMPULAN DAN SARAN	9
4.1 Kesimpulan	9
4.2 Saran.....	9
DAFTAR PUSTAKA.....	10

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi telah mendorong pertumbuhan data teks dalam jumlah yang sangat besar, seperti berita, artikel ilmiah, dan dokumen digital lainnya. Hal ini menimbulkan tantangan baru dalam pengolahan informasi, khususnya dalam memahami dan mengekstraksi inti dari dokumen panjang secara efisien. Salah satu solusi yang dilakukan adalah sistem peringkasan teks otomatis, yang bertujuan untuk menghasilkan ringkasan singkat namun tetap merepresentasikan informasi utama dari teks sumber.

Sebagai salah satu perguruan tinggi terkemuka di Indonesia, Universitas Bengkulu memiliki peran strategis dalam menghasilkan dan mendistribusikan informasi yang relevan, baik untuk kebutuhan akademik maupun administrasi. Universitas Bengkulu perlu memanfaatkan teknologi informasi guna meningkatkan efisiensi informasi menjadi informasi yang ringkas dan efisien. Dengan adanya teknologi peringkasan teks otomatis, institusi ini dapat mengelola informasi tersebut secara lebih efektif, mempermudah akses bagi pemangku kepentingan seperti dosen, mahasiswa, dan tenaga administrasi.

Metode tradisional untuk peringkasan teks, seperti algoritma statistik atau berbasis aturan, sering kali gagal menangkap hubungan kontekstual yang kompleks antar kata. Oleh karena itu, pendekatan berbasis *deep learning*, khususnya dengan arsitektur *Encoder – decoder* dan mekanisme *Attention*, menjadi solusi efektif. Model ini mampu memahami pola sekuensial dan menangkap informasi relevan dengan lebih baik, menghasilkan ringkasan yang lebih berkualitas. Dalam penelitian yang dilakukan oleh Kartha et al., (2024) *text summarization* menggunakan *encoder – decoder LSTM* dengan *Attention* meningkatkan ringkasan dengan menangkap hubungan kontekstual dalam urutan *input*. Encoder memproses input, sementara decoder menghasilkan ringkasan, memanfaatkan mekanisme perhatian untuk fokus pada bagian teks yang relevan untuk meningkatkan koherensi. Hal ini juga dilakukan pada penelitian oleh Prabhu & Seema, (2022) untuk *text summarization* menggunakan *encoder – decoder LSTM* dengan *attention* meningkatkan ekstraksi konten yang signifikan dengan berfokus pada bagian yang relevan dari urutan input. Mekanisme *attention* memungkinkan model untuk menimbang pentingnya kata – kata yang berbeda, meningkatkan akurasi ringkasan.

Penelitian ini berfokus pada pengembangan sistem *text summarization* menggunakan *Long Short – Term Memory (LSTM)* sebagai komponen utama dari Encoder dan Decoder,

dilengkapi dengan mekanisme *Attention* pada ulasan *google* pada *Google Maps* Universitas Bengkulu. Sistem ini dirancang untuk meningkatkan akurasi dan kualitas ringkasan teks dibandingkan metode konvensional.

1.2 Rumusan Masalah

Rumusan masalah pada penelitian ini adalah sebagai berikut:

1. Bagaimana merancang *text summarization* Universitas Bengkulu menggunakan arsitektur *Encoder – decoder* dengan LSTM dan mekanisme *Attention*?

1.3 Batasan Masalah

Batasan masalah dalam penelitian ini disusun guna penelitian fokus pada lingkup penelitian. Adapun batasan masalah sebagai berikut:

1. Dataset diambil dengan *scraping* dari ulasan *google* pada *Google Maps* Universitas Bengkulu.
2. Model yang dihasilkan tidak diimplementasikan ke tahap *deployment*.

1.4 Tujuan Penelitian

Tujuan penelitian adalah sebagai berikut:

1. Mengembangkan model *text summarization* berbasis arsitektur *encoder – decoder* dengan LSTM dan mekanisme *Attention*.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Menambah literatur tentang penerapan *deep learning*, khususnya arsitektur *encoder – decoder*, untuk *text summarization*.
2. Memberikan solusi bagi pengguna yang membutuhkan sistem otomatis untuk meringkas teks panjang secara efisien.

BAB II

TINJUAN PUSTAKA

2.1 *Deep Learning*

Deep learning (DL) adalah cabang kecerdasan buatan (AI) yang memungkinkan mesin untuk melakukan tugas – tugas yang secara tradisional membutuhkan kecerdasan manusia, memanfaatkan teknik dan algoritma canggih untuk mencapai akurasi dan efisiensi tinggi di berbagai aplikasi, termasuk pengenalan gambar dan pemrosesan bahasa (Rane et al., 2024). *Deep learning* telah banyak diteliti pada berbagai bidang, salah satunya pada bidang *Natural Language Processing* pada *text summarization*. Salah satunya pada penelitian Sarwar et al., (2022) yaitu menyesuaikan model pra-terlatih seperti *Longformer* Encoder - decoder telah menunjukkan peningkatan yang signifikan dalam akurasi ringkasan, terutama dalam konteks hukum, mencapai skor ROUGE 53,11% untuk kumpulan data tertentu.

2.2 *Text Summarization*

Text Summarization merupakan salah satu bidang penelitian dalam *Natural Language Processing* (NLP) yang bertujuan untuk menghasilkan ringkasan singkat dari teks asli tanpa mengurangi esensi informasinya *Text Summarization* menggunakan model *encoder – decoder* telah berkembang secara signifikan, mengintegrasikan berbagai metodologi untuk meningkatkan kinerja dalam tugas ringkasan ekstraktif dan abstraktif (Solanki et al., 2024). Menurut penelitian oleh Rehman et al., (2022), metode abstraktif semakin banyak digunakan karena mampu menghasilkan ringkasan yang lebih natural dengan memahami konteks, dibandingkan metode ekstraktif yang hanya memilih kalimat dari teks asli tanpa modifikasi.

2.3 *Attention Mechanism*

Attention Mechanism adalah komponen penting dalam berbagai arsitektur pembelajaran mendalam, meningkatkan kinerja model dengan memungkinkan fokus selektif pada informasi yang relevan dalam data input. Mekanisme ini telah diterapkan secara efektif di beberapa domain, termasuk prediksi lalu lintas, analisis sentimen, pemilihan fitur gambar, dan pembelajaran penguatan. *Attention Mechanism* sangat penting dalam pembelajaran mendalam, terutama untuk data berurutan. *Attention Mechanism* memungkinkan model untuk fokus pada informasi yang relevan, meningkatkan kinerja dalam tugas-tugas seperti analisis sentimen dengan mengatasi keterbatasan model urutan ke urutan tradisional, sehingga meningkatkan akurasi dalam deteksi polaritas sentimen (P & Jose, 2024).

2.4 Long Short – Term Memory (LSTM)

Long Short – Term Memory (LSTM) adalah jenis jaringan saraf tiruan yang dirancang untuk mengatasi masalah yang dihadapi oleh jaringan saraf tradisional, terutama dalam konteks pemrosesan urutan data. LSTM memiliki struktur yang unik dibandingkan dengan jaringan saraf konvensional. Setiap unit LSTM terdiri beberapa komponen utama yaitu sel memori (*memory cell*), gerbang *input* (*input gate*), gerbang lupa (*forget gate*), dan gerbang *output* (*output gate*). Model LSTM secara signifikan meningkatkan akurasi prediksi di pasar keuangan, mencapai akurasi rata-rata 95,53% dibandingkan dengan 87,89% untuk model tradisional (Bi & Wang, 2024). Dengan menganalisis data historis, LSTM membantu dalam membuat keputusan berdasarkan informasi tentang tren pasar masa depan.

2.5 Encoder – decoder

Arsitektur *encoder – decoder* adalah kerangka kerja penting dalam pemrosesan bahasa alami (NLP), terutama untuk tugas-tugas seperti terjemahan mesin. Struktur ini biasanya terdiri dari dua komponen utama encoder, yang memproses data input dan mengompresnya menjadi vektor konteks, dan decoder, yang menghasilkan urutan keluaran dari vektor ini. Metode *encoder – decoder* adalah arsitektur jaringan saraf yang digunakan untuk tugas-tugas seperti terjemahan mesin. Mereka terdiri dari encoder yang memproses data input dan decoder yang menghasilkan output, secara efektif mengubah satu urutan menjadi urutan lainnya, seperti yang ditunjukkan dalam makalah dengan terjemahan bahasa (Surdeanu & Valenzuela-Escárcega, 2024).

BAB III

HASIL DAN PEMBAHASAN

3.1 *Business Understanding*

Dalam era digital, Universitas Bengkulu sebagai institusi pendidikan tinggi menghadapi tantangan dalam mengelola data teks. Data memerlukan pengolahan yang efisien agar informasi penting dapat disampaikan secara cepat dan tepat kepada berbagai pihak, termasuk dosen, mahasiswa, tenaga administrasi, dan masyarakat umum.

Oleh karena itu, pengembangan sistem peringkasan teks otomatis dapat menjadi solusi efektif dalam membantu mengelola informasi tersebut. Sistem ini bertujuan untuk menghasilkan ringkasan singkat yang tetap akurat dan informatif, sehingga pengguna dapat dengan mudah memahami inti dari dokumen panjang tanpa membaca keseluruhan teks.

3.2 *Data Understaning*

Data ialah sekumpulan informasi mentah yang dalam penelitian ini berupa kata-kata atau teks. Pengumpulan data dilakukan secara primer dengan mengambil ulasan pengguna yang didapatkan dari ulasan *google* pada *Google Maps* Universitas Bengkulu. Data ini terdiri atas 219 ulasan pengguna yang memuat komentar berupa teks.

3.3 *Data Preparation*

Tahapan data preparation melewati beberapa proses yaitu:

1. *Scraping Data*

Proses *scraping* data merupakan proses pengumpulan data dari internet untuk diolah dan disimpan dalam format tertentu. Pada penelitian ini proses tersebut dilakukan menggunakan bahasa pemrograman python dan selenium, dimana selenium akan digunakan untuk menelusuri URL target pada web, sementara program akan mencari XPath yang sesuai untuk mengambil ulasan pengguna di laman *Google Maps* Universitas Bengkulu. Proses ini hanya dikhususkan untuk mengambil komentar tanpa mengikutsertakan *username* pengguna serta ulasan dengan rating bintang.

2. *Data Preprocessing*

Data mentah yang telah dikumpulkan selanjutnya akan diberi label. Dalam penelitian ini label yang dilakukan pada data berupa ringkasan kalimat dari data mentah. Setelah proses pelabelan selesai maka data tersebut dapat dibersihkan.

Pembersihan ini meliputi menghapus teks duplikat, menghapus baris yang kosong dan menghapus tag HTML. Proses ini disebut sebagai *text cleaning*.

Data kemudian diubah menjadi *lower case* dan melakukan tokenisasi teks dan menyaring token yang bukan alfanumerik. Selanjutnya dilakukan penghapusan data teks terhadap kata yang tidak mengandung informasi atau makna yang disebut *stopword*. Penelitian ini menggunakan *stopword* berbahasa Indonesia dari *library NLTK*.

Untuk melakukan pelatihan pada model maka data perlu dibagi menjadi dua yaitu *data train* dan *data test* dengan *rasion* 90% data digunakan untuk pelatihan dan 10% data digunakan untuk pengujian. Data yang telah dibagi kemudian melalui proses tokenisasi menggunakan *Tokenizer* untuk mengubah teks menjadi deret angka unik. Untuk memastikan panjang deret antar tiap data konsisten maka digunakan *padding* dengan metode *post*. Data keluaran lalu dipecah menjadi *decoder_input_data* dan *decoder_target_data* untuk mempersiapkan pelatihan model *sequence – to – sequence*.


3.4 Modeling

Pada tahapan permodelan, model *encoder – decoder* dengan *attention mechanism* dibangun untuk menghasilkan keluaran berupa urutan kata secara bertahap. Proses dimulai dengan *encoder* yang memproses urutan input menggunakan *embedding* dan *LSTM*, menghasilkan *context vector* berupa *state_h* dan *state_c*, serta keluaran sekuensial *encoder_outputs*. Kemudian, *decoder* memproses input dari keluaran sebelumnya melalui *embedding* dan *LSTM*, dengan menggunakan *state_h* dan *state_c* dari *encoder* sebagai *initial state*.

Selanjutnya, *attention mechanism* diterapkan melalui lapisan yang menghitung hubungan antara keluaran *decoder* dan keluaran *encoder*. Hasil dari lapisan *attention* digabungkan dengan keluaran *decoder* menggunakan lapisan *Concatenate* untuk memperkaya representasi. Akhirnya, lapisan *dense* dengan aktivasi *softmax* digunakan untuk menghasilkan probabilitas kata pada kosakata target. Model ini dikompilasi dengan *optimizer rmsprop* dan fungsi *loss sparse_categorical_crossentropy* untuk pelatihan.


3.5 Evaluasi

Evaluasi model dilakukan berdasarkan metrik akurasi dan *loss* yang diperoleh selama proses pelatihan. Hasil evaluasi menggambarkan kemampuan model untuk menghasilkan ringkasan dari teks sumber.



Gambar 1 Grafik Akurasi

Pada grafik gambar diatas, terlihat bahwa akurasi model terhadap data latih dan uji meningkat setiap epoch. Kedua kurva tersebut menunjukkan peningkatan dengan akurasi akhir mencapai 76%. Dengan tingkat akurasi 76%, model mampu menghasilkan ringkasan yang cukup baik, meskipun model masih bisa dilakukan peningkatan dalam menyajikan informasi yang lebih akurat.



Gambar 2 Grafik *Loss*

Grafik *loss* pada Gambar 2 menunjukkan penurunan bertahap selama pelatihan, ini menggambarkan kemampuan model untuk meminimalkan kesalahan prediksi. Nilai *loss* akhir sebesar 1.3172 menunjukkan bahwa model berhasil mengurangi kesalahan selama pelatihan, tetapi optimasi lebih lanjut dapat dilakukan untuk meningkatkan performa.

3.6 Analisa Model sebagai *Deep Learning*

Model yang digunakan dalam penelitian ini, yaitu arsitektur *encoder – decoder* dengan LSTM dan mekanisme *Attention*, dikategorikan sebagai *deep learning*. Hal ini disebabkan karena model *deep learning* menggunakan banyak lapisan (*layers*) untuk memproses data. Dalam penelitian ini *Encoder* dan *Decoder* pada LSTM memiliki beberapa lapisan tersembunyi (*hidden layers*) yang dirancang untuk menangkap pola kompleks dalam teks sumber. Mekanisme *Attention* memungkinkan model untuk berfokus pada bagian penting dari teks, menambahkan tingkat kompleksitas yang lebih tinggi dibandingkan model *shallow learning*. Mekanisme *Attention* meningkatkan kemampuan model untuk memahami konteks panjang, sehingga ringkasan yang dihasilkan menjadi lebih relevan.

Berdasarkan analisis di atas, arsitektur model ini memenuhi karakteristik *deep learning* karena kedalaman arsitektur, kemampuan pembelajaran fitur kompleks secara otomatis, kapasitas untuk menangani data. Oleh karena itu, model ini tidak dapat dikategorikan sebagai *shallow learning*, yang umumnya hanya menggunakan satu lapisan tersembunyi atau kurang kompleks dalam menangkap pola data.

BAB IV

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan penelitian yang dilakukan, dapat disimpulkan bahwa model *text summarization* dengan *deep learning* dengan arsitektur *encoder – decoder* menggunakan LSTM dan mekanisme *Attention* telah berhasil dikembangkan untuk menghasilkan ringkasan teks otomatis. Model mencapai akurasi sebesar 76% pada data pelatihan dengan nilai loss akhir sebesar 1.3172, yang menunjukkan kemampuan model dalam menghasilkan ringkasan yang cukup relevan dan informatif.

4.2 Saran

Penelitian ini dapat dikembangkan lebih lanjut dengan beberapa saran yang dapat dilakukan adalah menggunakan dataset yang lebih besar dan lebih beragam, termasuk data khusus dari Universitas Bengkulu, untuk meningkatkan generalisasi model. Melakukan *fine – tuning hyperparameter* atau mencoba arsitektur *deep learning* lainnya, seperti Transformer atau BERT, untuk meningkatkan akurasi model.

DAFTAR PUSTAKA

- Bi, C., & Wang, Y. (2024). Long Short Term Memory Network (LSTM) Model Based on Neural Networks in Financial Forecasting. *2024 Second International Conference on Networks, Multimedia and Information Technology (NMITCON)*, 1–5. <https://doi.org/10.1109/NMITCON62075.2024.10699249>
- Kartha, R. S., Agal, S., Odedra, N. D., Nanda, C. S. K., Rao, V. S., Kuthe, A. M., & Taloba, A. I. (2024). NLP-Based Automatic Summarization using Bidirectional Encoder Representations from Transformers-Long Short Term Memory Hybrid Model: Enhancing Text Compression. *International Journal of Advanced Computer Science and Applications*, 15(5), 1223–1236. <https://doi.org/10.14569/IJACSA.2024.01505124>
- P, D., & Jose, A. C. (2024). A Review of Attention Based Model for Sentimental Analysis using NLP. *2024 International Conference on Advancements in Power, Communication and Intelligent Systems (APCI)*, 1–6. <https://doi.org/10.1109/APCI61480.2024.10616401>
- Prabhu, B. R., & Seema, S. (2022). Sentiments Analysis and Text Summarization of Medicine Reviews Using Deep Sequential Iterative Model with Attention Encoder. *Journal of Mobile Multimedia*, 18(4), 1281–1300. <https://doi.org/10.13052/jmm1550-4646.18415>
- Rane, N. L., Mallick, S. K., Kaya, Ö., & Rane, J. (2024). Techniques and optimization algorithms in deep learning: A review. In *Applied Machine Learning and Deep Learning: Architectures and Techniques*. Deep Science Publishing. https://doi.org/10.70593/978-81-981271-4-3_3
- Rehman, T., Das, S., Sanyal, D. K., & Chattopadhyay, S. (2022). *An Analysis of Abstractive Text Summarization Using Pre-trained Models*. 253–264. https://doi.org/10.1007/978-981-19-1657-1_21
- Sarwar, A., Latif, S., Irfan, R., Ul-Hasan, A., & Shafait, F. (2022). Text Summarization from Judicial Records using Deep Neural Machines. *International Conference on Electrical, Computer, Communications and Mechatronics Engineering, ICECCME 2022*. <https://doi.org/10.1109/ICECCME55909.2022.9987795>
- Solanki, S., Jain, S., & Bandhu, K. C. (2024). Fusion of Word Embedding and Encoder Decoder Model for Text Summarization. *2024 IEEE 13th International Conference on Communication Systems and Network Technologies (CSNT)*, 1146–1150. <https://doi.org/10.1109/CSNT60213.2024.10546173>
- Surdeanu, M., & Valenzuela-Escárcega, M. A. (2024). Implementing Encoder-Decoder Methods. In *Deep Learning for Natural Language Processing: A Gentle Introduction* (pp.

229–245). Cambridge University Press.